



Universidad
Nacional
de Loja

Facultad de Energía, las Industrias y los Recursos Naturales no Renovables

CARRERA DE INGENIERÍA EN SISTEMAS

Modelo predictivo basado en visión por computador para identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro.

Predictive model based on computer vision to identify late blight disease (*Phytophthora infestans*) on kidney tomato (*Solanum Lycopersicum*) leaves in Cantón Saraguro.

Línea de investigación: Inteligencia Artificial

PROYECTO DE TITULACIÓN EN INGENIERÍA EN SISTEMAS.
--

Autor:

◊ 0000-0003-2180-5118, Sisa Ñusta Parra Tene, sisa.parra@unl.edu.ec

Tutor:

- Roberth Gustavo Figueroa Díaz, Mg.Sc

Cotutor:

- Roberth Gustavo Figueroa Díaz, Mg.Sc



Carrera de Ingeniería en
Sistemas / Computación

LOJA - ECUADOR

2022

Certificación de Tutoría

En calidad de Tutor y Cotutor del Proyecto de Trabajo de Titulación PTT, certificamos la tutela a Sisa Ñusta Parra Tene y , con el tema **Modelo predictivo basado en visión por computador para identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro. - Predictive model based on computer vision to identify late blight disease (*Phytophthora infestans*) on kidney tomato (*Solanum Lycopersicum*) leaves in Cantón Saraguro.**, quienes han cumplido con todas las observaciones requeridas. Es todo cuanto puedo decir en honor a la verdad, facultando a los interesados hacer uso de la presente, así como el trámite de pertinencia del presente proyecto.

Loja, 11 de noviembre de 2022

Atentamente,

Roberth Gustavo Figueroa Díaz, Mg.Sc
TUTOR

Roberth Gustavo Figueroa Díaz, Mg.Sc
COTUTOR

Certificación de Autoría del Proyecto

Yo, Sisa Ñusta Parra Tene, estudiante de la Universidad Nacional de Loja, declaro en forma libre y voluntaria que el presente Proyecto de Trabajo de Titulación que versa sobre **Modelo predictivo basado en visión por computador para identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro.- Predictive model based on computer vision to identify late blight disease (*Phytophthora infestans*) on kidney tomato (*Solanum Lycopersicum*) leaves in Cantón Saraguro.**, así como las expresiones vertidas en la misma son autoría del compareciente, quien ha realizado en base a recopilación bibliográfica primaria y secundaria. En consecuencia asumo la responsabilidad de la originalidad de la misma y el cuidado al remitirse a las fuentes bibliográficas respectivas para fundamentar el contenido expuesto.

Atentamente,

Sisa Ñusta Parra Tene

Índice general

1. Problemática	1
1.1. Situación Problemática	1
1.2. Problema de investigación	3
2. Justificación	4
3. Objetivos	5
3.1. General	5
3.2. Específicos	5
4. Alcance	6
5. Marco Teórico	8
5.1. Antecedentes	8
5.1.1. Cultivo de tomate de riñón	8
5.1.2. Enfermedades causadas por hongos	8
5.2. Fundamentos teóricos	10
5.2.1. Inteligencia Artificial (IA)	10
5.2.2. Machine learning (ML)	10
5.2.3. Deep Learning (DL)	10
5.2.4. Redes Neuronales Convolucionales (CNN)	11
5.2.5. Arquitectura de una red Neuronal	11
5.2.6. Visión por Computador	13
5.2.7. Reconocimiento de objetos	14
5.2.8. Matriz de confusión	15
5.2.8.1. La matriz de confusión como herramienta del aprendi- zaje automático	15
5.2.9. Python	16
5.2.9.1. Ventajas de Python con Inteligencia Artificial	17
5.2.10. Keras	18
5.2.11. TensorFlow	19
5.3. Trabajos relacionados	20
6. Metodología	23
7. Cronograma	24

8. Presupuesto	26
8.1. Recursos Humano	26
8.2. Recursos Tecnológico	26
8.3. Recursos Materiales	27
8.4. Servicios	27
8.5. Presupuesto total para la elaboración del proyecto	27
Bibliografía	29
Lista de Acrónimos y Abreviaturas	32
A. Anexo I. Modelo de la entrevista	33

Índice de figuras

5.1. Arquitectura de Red Neuronal[1]	12
5.2. Arquitectura de convolución[2]	12
5.3. Reducción – pooling[2]	13
5.4. Etapas de un Sistema de Visión Artificial[3]	14
5.5. Detección de imagen[4]	15
5.6. Matriz de confusión binaria[4]	16
6.1. Metodología del PTT	23
7.1. Cronograma del PTT	25
A.1. Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.1	33
A.2. Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.2	34
A.3. Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.3	35

Índice de tablas

5.1. Trabajos relacionados	22
8.1. Recursos Humanos	26
8.2. Recursos Tecnológico	26
8.3. Recursos Materiales	27
8.4. Servicios	27
8.5. Presupuesto total para la elaboración del proyecto	27

Modelo predictivo basado en visión por computador para identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro.

Predictive model based on computer vision to identify late blight disease (*Phytophthora infestans*) on kidney tomato (*Solanum Lycopersicum*) leaves in Cantón Saraguro.

Línea de investigación: Inteligencia Artificial

1. Problemática

1.1. Situación Problemática

El cultivo de tomate (*Solanum lycopersicum*) se encuentra entre las hortalizas de mayor importancia a nivel mundial [5]. Según las estadísticas de la Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO), en el año 2020 se produjeron en el mundo 186.821 millones de kilos de tomate, teniendo en cuenta que los mayores productores de tomate a nivel mundial, son China con una producción de 64.768'16 millones de kilos, seguido de India con 20.573 millones de kilos, Turquía ocupa la tercera posición con un volumen de 13.204'01 millones de kilos, y el cuarto lugar es de Estados Unidos con 12.227'4 millones de kilos [6]. Sin embargo, al ser un producto delicado y susceptible a los cambios climáticos, no está a salvo de las enfermedades causadas por hongos y plagas, que disminuyen la vida útil de las plantas, limitando su producción y comercialización, siendo a la vez causante de grandes pérdidas económicas en los agricultores [7], ya que según investigaciones la presencia de enfermedades en el cultivo de tomate puede causar pérdidas de hasta un 60% de la producción, ocasionando la reducción de la superficie sembrada [8]. Son muchas las enfermedades que pueden afectar al cultivo del tomate, entre ellas se encuentran; Moho de la hoja (*Cladosporium fulvum*), Podredumbre causada por *Alternaria alternata*, Mancha gris (*Stemphylium solani*), Viruela (*Septoria lycopersici*), Peca bacteriana (*Pseudomonas syringae*), Mancha bacteriana (*Xanthomonas campestris*), Podredumbres de raíz o cuello de la planta y marchitamientos, Podredumbre húmeda del tallo provocadas por *Sclerotinia* spp. Podredumbre de cuello y raíces (a consecuencia de *Phytophthora* parasítica), *Fusarium solani*, el Cáncer bacteriano (*Clavibacter michiganensis*), Podredumbre basal del tallo provocada por *Sclerotium rolfsii*, etc. En condiciones de alta incidencia y severidad, estas enfermedades provocan pérdidas de rendimiento del tomate y por ende en la economía [9].

En Ecuador el tomate de riñón fresco consumido en el mercado proviene en su totalidad de la producción nacional, de acuerdo al Boletín situacional emitido por el Ministerio de Agricultura y Ganadería, en el año 2017 se ha registrado una producción total de 578 toneladas de tomate de riñón, lo cual significa un incremento del 13% con respecto al año 2016, en donde obtuvieron 512 Toneladas, sin embargo la producción del año 2017 es bastante baja con respecto al 2014 que fue el de mayor rendimiento en todo el periodo analizado, con un total de 662 Toneladas [10]. Este comportamiento, según distintas investigaciones [11] se debe a que en Ecuador existe un sin número de plagas y enfermedades que son de importancia económica, ya que traen consigo un alto

porcentaje de pérdidas de la producción y rendimiento de los cultivos de tomate de riñón. Debido a las condiciones de alta temperatura y humedad, el cultivo se ve afectado por diversas enfermedades que causan daños e inclusive pérdida total, por tal motivo los agricultores no están aferrados en la siembra de tomate en grandes dimensiones, ya que temen ser afectado por estas situaciones, además, debido a la falta de conocimientos para reconocer de forma temprana los síntomas de distintas enfermedades en el cultivo ha evitado que puedan brindar un tratamiento oportuno a sus plantaciones [11].

El cantón Saraguro, es un pueblo que se caracteriza por ser eminentemente agrícola, en donde el 80% al 95% de la economía depende de la agricultura y ganadería, entre los productos que se siembran en este sector, se encuentran en gran cantidad los cultivos de tomate de riñón, mismos que se producen mayormente en invernaderos debido al clima y tipo de tierra que se tiene [12][13].

En el Gobierno Autónomo Descentralizado del Cantón Saraguro (GADMIS), se realizó la entrevista al técnico del Departamento de Gestión Ambiental y Producción, con el objetivo de recolectar información acerca del cultivo del tomate de riñón dentro de este sector, obteniendo que, este producto es sembrado cuantiosamente por pequeños y medianos productores en invernaderos (bajo cubierto) y al aire libre, convirtiéndose en una fuente importante para el ingreso económico del agricultor. Con base en la entrevista, se puede destacar también que, debido al clima y tipo de suelo que tiene el área geográfica de Saraguro, las variedades de tomate que mejor se han adaptado son *pietro*, *titán* y *el dominique*, (véase en A. ANEXO I Pregunta 1-4), que son cultivados durante todo el año para ser comercializados dentro y fuera de la localidad, significando un 60% del ingreso económico del productor. Sin embargo, en varias ocasiones se ha sufrido grandes pérdidas tanto, económicas como de producción, debido a que esta planta es muy susceptible a ataque de plagas y enfermedades, entre las cuales se encuentran más comúnmente la Cenicilla (*Oidium*), tizón tardío, *Fusarium* (Marchitamiento), mancha gris, *botrytis*, y mosca blanca, que suelen presentarse a principios o finales del cultivo, dando sus primeros brotes en la hoja y si no es controlada a tiempo pasa al tallo y finalmente al fruto. Esto puede llegar a perjudicar gran parte de la producción y en ocasiones hasta el 100% del plantío (véase en A. ANEXO I Pregunta 3-5-7).

Uno de los problemas más relevantes en cuanto a las enfermedades que afectan a la plantación de tomate, según lo menciona el técnico de fomento agropecuario, (véase en A. ANEXO I Pregunta 6), es que los agricultores no están totalmente capacitados para identificar el tipo de enfermedad que presenta su cultivo, por lo cual en su afán de prevenirlas antes de que afecte a la mayor parte del sembrío, optan por la aplicación de insumos químicos u orgánicos que en ocasiones resultan ser innecesarios o no recomendados para tratar cierta enfermedad, lo cual genera gasto económico y daño al medio ambiente y ser humano en el caso del uso indiscriminado de fungicidas. Aunque el municipio cuenta con un departamento a cargo de la gestión de producción, no tiene el personal necesario para cubrir todas las zonas de cultivo de tomate, el agrónomo no dispone de tiempo necesario para llevar a cabo un seguimiento minucioso a todos los

sectores de producción, (véase en A. ANEXO I Pregunta 8-9). Por lo tanto, basándose en este contexto, y en búsqueda de brindar soluciones a los problemas que se presentan en esta área agrícola, el presente proyecto se orienta a la aplicación de nuevas tecnologías que vayan en beneficio de los pequeños y grandes agricultores, haciendo uso de herramientas como es visión por computador para ayudar a determinar a tiempo el tipo de enfermedad que ataca al cultivo de tomate de riñón, permitiendo que se pueda brindar oportuno tratamiento con el fin de mejorar la producción tanto en calidad, y cantidad de cosecha.

1.2. Problema de investigación

En base a la problemática planteada, el presente proyecto está dirigido al Departamento de Gestión Ambiental y Producción del Municipio del cantón Saraguro, centralizándose en la identificación de enfermedades en las hojas del tomate de riñón que afectan a una gran cantidad del cultivo, en consecuencia, se deduce que el problema de investigación para el presente proyecto de trabajo de titulación es:

¿Podrá el modelo predictivo basado en visión por computador identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro.?

¿Will the predictive model based on computer vision be able to identify the Late Blight disease (*Phytophthora infestans*) on leaves of kidney tomato (*Solanum Lycopersicum*) in Cantón Saraguro?

2. Justificación

El cultivo de tomate de riñón en el cantón Saraguro, es significativamente importante, ya que sus productos son utilizados tanto para el consumo familiar como para comercialización, teniendo gran demanda en el mercado local, por lo tanto, es indispensable que existan técnicas que ayuden al cuidado de los mismos. Con base en esto, el presente proyecto se justifica en dentro del ámbito social, porque pretender ser el apoyo del agricultor, ayudándole a determinar a tiempo las enfermedades que afectan su cultivo, lo cual le permite aplicar tratamientos oportunos y de acuerdo a lo que la plantación necesita. El tratar prematuramente el cultivo evita la propagación de enfermedades o plagas que pueden minimizar la cantidad de cosecha o calidad del producto, pero que siendo tratados a tiempo evita daños[13].

La agricultura ha mostrado interés en la tecnología de visión por computador, puesto que este campo permite realizar de forma automática y eficaz diversas operaciones del ciclo productivo agrícola, desde la siembra hasta la cosecha. En el aspecto académico se justifica, ya que busca aplicar herramientas tecnológicas como lo de visión por computador para ayudar a los agricultores a determinar la enfermedad que tiene su cultivo de tomate, convirtiéndose en una herramienta no solo para el agricultor, sino también para el municipio, por el hecho de que le permite dar el seguimiento a los cultivos sin la necesidad de estar presentes en el lugar.

La puesta en marcha del presente proyecto de titulación constituye un aporte valioso, puesto que beneficiará a los medianos y pequeños productores, de tomate de riñón, por otra parte, la UNL se encuentra en las posibilidades de brindar el apoyo necesario para que se lleve a cabo este trabajo; lo más importante es la oportunidad de contar con ingeniero Agrónomo, se justifica en pilares fundamentales como el científico porque promueve la investigación bibliográfica de técnicas, algoritmos de inteligencia artificial aplicables en la detección y clasificación de imágenes; para conjuntamente construir la propuesta que permite aplicar los conocimientos adquiridos durante los cinco años de formación profesional, aportando al campo científico y social con una solución innovadora sobre el problema detectado, con el fin de fomentar el uso de las Tics.

3. Objetivos

3.1. General

Diseñar un modelo predictivo basado en visión por computador para identificar la enfermedad del Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón (*Solanum Lycopersicum*) del Cantón Saraguro.

Design a predictive model based on computer vision to identify the Late Blight disease (*Phytophthora infestans*) in leaves of kidney tomato (*Solanum Lycopersicum*) in Saraguro Canton.

3.2. Específicos

- Identificar métodos, técnicas basadas en inteligencia artificial y recopilar data sets con imágenes de hojas sanas y enfermas del tomate de riñón.

Identify methods, techniques based on artificial intelligence and compile data sets with images of healthy and diseased leaves of kidney tomato.

- Desarrollar un modelo de visión por computador para la detección automática de la enfermedad Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón.

Develop a computer vision model for automatic detection of Late Blight (*Phytophthora infestans*) disease in kidney tomato leaves.

- Validar el modelo de visión por computador en un escenario de prueba aplicada a los invernaderos del cantón Saraguro.

Validate the computer vision model in a test scenario applied to greenhouses in the Saraguro canton.

4. Alcance

El presente proyecto de titulación comprende en él “Modelo predictivo basado en visión por computador para identificar enfermedades en las hojas del tomate de riñón (*Solanum Lycopersicum*) del cantón Saraguro”, mediante el reconocimiento de imágenes. A continuación, se detallan las actividades a seguir por cada objetivo específico planteado:

- **FASE 1: Identificar métodos, técnicas basadas en inteligencia artificial y recopilar data sets con imágenes de hojas sanas y enfermas del tomate de riñón.**
 1. Revisar información relacionada al tema de investigación para identificar métodos y técnicas utilizados en el desarrollo de modelos basados en visión por computador.
 2. Buscar en data sets y bases de datos imágenes accesibles de la hoja de tomate de riñón.
 3. Adquirir los datos mediante, imágenes de hoja de tomate de riñón, que permita entrenar, evaluar el modelo y distinguir la enfermedad.
 4. Preparar los datos mediante el etiquetado de imágenes, que cumplen con los criterios de aceptación y basándose en el formato permitido por los modelos.
 5. Dividir en set de datos en Entrenamiento, Validación y Prueba.
- **FASE 2: Desarrollar un modelo de visión por computador para la detección automática de la enfermedad Tizón Tardío (*Phytophthora infestans*) en las hojas del tomate de riñón.**
 1. Utilizar un modelo de visión por computador, para construir un modelo capaz de diagnosticar la enfermedad a partir de las hojas de tomate de riñón.
 2. Construir el modelo para determinar la enfermedad en la hoja de tomate de riñón.
 3. Entrenar el modelo utilizando el conjunto de datos obtenidos para el entrenamiento.
- **FASE 3: Validar el modelo de visión por computador en un escenario de prueba aplicada a los invernaderos del cantón Saraguro.**

1. Evaluar los resultados obtenidos por el modelo en cuanto al diagnóstico de enfermedad en la hoja de tomate de riñón.
2. Validar y contrastar los resultados obtenidos en un escenario de prueba con la opinión de un experto.

5. Marco Teórico

5.1. Antecedentes

5.1.1. Cultivo de tomate de riñón

El tomate de riñón es la hortaliza más cultivada en el mundo, por su contenido nutricional, el cultivo de tomate riñón (*Solanum lycopersicum*) en el Ecuador alcanza una producción de 31,891 toneladas métricas, de las que 26,946 toneladas métricas se producen en la Sierra en las provincias de Carchi, Chimborazo y Tungurahua principalmente; en la región Costa 4,946 toneladas métricas en las provincias de Guayas y Manabí. El cultivo se establece a campo abierto y también en invernadero. La planta de tomate (*Solanum lycopersicum*) tiene su centro de origen en los Andes de América del Sur y su centro de domesticación se encuentra en América Central. Después de la llegada de los españoles fue transportada a Europa, donde se empezaron trabajos de fitomejoramiento y se popularizó el consumo del mismo para ser producido en América del Sur [14].

Es un alimento muy versátil, se consume casi todo el año y que tiene grandes propiedades nutritivas. No tiene grasas y tiene un alto contenido acuoso que supera el 90%, contiene micronutrientes, potasio, magnesio, sodio, fósforo. Además, tiene un buen aporte de fibra, vitamina C y su riqueza en carotenos, hacen que el tomate es un excelente antioxidante que ha demostrado tener efectos protectores contra diferentes tipos de cáncer. Incluso, su poder antiinflamatorio reduce las probabilidades de sufrir arteriosclerosis y disminuye los niveles de colesterol, por lo tanto, también protege ante infartos y otras enfermedades cardiovasculares[15].

5.1.2. Enfermedades causadas por hongos

- **Tizón tardío (*Phytophthora infestans*)**

El tizón tardío causado por el oomiceto *Phytophthora infestans* es una de las enfermedades más destructivas que amenaza la seguridad alimentaria mundial, es causante de pérdidas de rendimiento y calidad del tomate y papa. El hongo penetra por los estomas, tiene rápida capacidad de multiplicarse y es capaz de atacar a muchas plantas, se propaga a través de la lluvia, viento y grietas en invernaderos. Presenta manchas oleosas en las hojas y en los frutos, manchas pardas, jaspeadas y abolladas[16].

- **Tizón temprano (*Alternaria solani*)** El agente causal de la enfermedad es *Alternaria solani*, a la enfermedad se conoce como tizón temprano. Esta enfermedad causa daños graves en todas las etapas de desarrollo de la planta. Presenta manchas pardas concéntricas en la hoja, manchas pardas alargadas en el tallo con una parte central de color gris, sus frutos de color oscuro, sépalos necrosados y consecuente caída de la flor. Se conoce que una *solani* causa destrucción en el contenido de fotosíntesis y pigmentos, lo que resulta inhibición general del crecimiento[16].
 - **Cenicilla (*Oidium* sp)** Los oídios son patógenos biótrosos fácilmente reconocibles por su masa pulverulenta sobre hojas, flores, tallos, peciolo. En ataques severos se pierden racimos florales, hojas e incluso plantas. El hongo se multiplica rápidamente y coloniza numerosas plantas a través de la lluvia, viento y en ciertos casos por personal que trabaja en el invernadero[16].
 - **Moho gris (*Botrytis cinérea*)** Es un hongo filamentoso patógeno de una gran variedad de huéspedes, se presenta en cultivos de importancia como tomate, fresa, etc. Puede atacar al cultivo en cualquier estado de desarrollo e incluso genera pérdidas del fruto en campo o almacenados. La sintomatología más común causada por la *botrytis*, es los anillos claros en la superficie del fruto, verdes o maduros, pero solo es una cuestión de apariencia. Además, moho gris en la hoja, racimos florales, frutos y tallos[16].
 - **Fusarium (*Fusarium oxysporum*)** El hongo ascomiceto, *F. Oxysporum* forma parte de un complejo grupo de especies que están distribuidas en múltiples entornos, suelo, ambientes interiores y hábitats acuáticos. Es una enfermedad de las raíces y del cuello de la planta, presenta marchitamiento en toda la planta, el interior del tallo de color café oscuro y la base de las raíces podridas. Esta enfermedad se propaga a través del agua de riego, lluvia, corrientes de aire y plantas contaminadas[16].
 - **Erwinia (*Erwinia carotovora*)** Bacteria peligrosa que penetra a través de heridas del tallo por medio del agua de riego y por las operaciones culturales de poda realizadas. Por el exceso de humedad y temperatura, esta enfermedad se presenta en frutos verdes o maduro como una lesión de color blanco opaco, consecutivamente se torna acuosa al invadir el fruto adoptando la forma de una bolsa con un líquido mal oliente que forma la descomposición de los tejidos[16].
-

5.2. Fundamentos teóricos

5.2.1. Inteligencia Artificial (IA)

La inteligencia artificial (IA) tiene por objeto que los ordenadores hagan la misma clase de cosas que puede hacer la mente. La inteligencia no es una dimensión única, sino un espacio profusamente estructurado de capacidades diversas para procesar la información. Del mismo modo, la IA utiliza muchas técnicas diferentes para resolver una gran variedad de tareas. La IA tiene dos objetivos principales. Uno es tecnológico: usar los ordenadores para hacer cosas útiles (a veces empleando métodos muy distintos a los de la mente). El otro es científico: usar conceptos y modelos de IA que ayuden a resolver cuestiones sobre los seres humanos y demás seres vivos. La mayoría de los especialistas en IA se concentra en un solo objetivo, aunque algunos contemplan ambos[17].

5.2.2. Machine learning (ML)

El aprendizaje automático fue propuesto por Samuel en 1959 y se ha aplicado ampliamente en visión por computador, juegos en general, economía, minería de datos y bioinformática, entre otras áreas. Con la madurez de la inteligencia artificial y el aprendizaje automático, no solo los investigadores en el campo principal de la inteligencia artificial están logrando avances importantes, sino también los expertos en otros campos que emplean estos métodos para lograr sus propios objetivos. Como rama de la inteligencia artificial, el aprendizaje automático utiliza grandes cantidades de datos para optimizar continuamente los modelos y hacer predicciones razonables bajo la guía de algoritmo[18]. En los últimos años, el aprendizaje automático (ML) ha sido reconocido como una herramienta ampliamente poderosa para el progreso tecnológico. A pesar del crecimiento de movimientos que aplican ML e inteligencia artificial (IA) a problemas de bien social y global, sigue existiendo la necesidad de un esfuerzo concertado para identificar cómo se pueden aplicar mejor estas herramientas para abordar el cambio climático. Muchos practicantes de ML desean actuar, pero no están seguros de cómo hacerlo. Por otro lado, muchos campos han comenzado a buscar activamente aportes de la comunidad ML[19].

5.2.3. Deep Learning (DL)

Aprendizaje profundo (DL) tiene claras ventajas para resolver problemas complejos, como el análisis y control de frecuencia del sistema de potencia, debido a su poderosa capacidad de análisis, predicción y clasificación de datos. En los

últimos años, el deep learning ha supuesto una auténtica revolución en el campo de la inteligencia artificial. Los resultados alcanzados tanto en aplicaciones científico-tecnológicas como económicas y sociales han propiciado que la demanda de especialistas en esta materia aumente de forma exponencial, así como los recursos para su aprendizaje. Sin embargo, hoy día la mayoría de los recursos existentes se centran en la aplicación práctica de las técnicas, pasando por alto los conceptos básicos que son imprescindibles para llegar a comprender esta tecnología. Las redes neuronales son una de las técnicas más utilizadas del aprendizaje automático (en inglés, machine learning). Este campo de la inteligencia artificial engloba a aquel algoritmo basado en modelos (representaciones matemáticas de la realidad) predefinidos que son ajustados sobre la base de los datos disponibles para resolver un problema específico[20].

5.2.4. Redes Neuronales Convolucionales (CNN)

Redes convolucionales (CNN), son modelos que se utilizan en mayor frecuencia para el procesamiento de imágenes y visión para ordenadores. Están diseñadas de tal manera que imitan la estructura de la corteza visual animal. Las redes de neuronas convolucionales tienen neuronas dispuestas en tres dimensiones: anchura, altura y profundidad. Aquí, las neuronas de una capa solamente están conectadas a una pequeña región de la capa anterior. La CNN es un tipo de Red Neuronal Artificial con aprendizaje supervisado que procesa sus capas imitando al cortex visual del ojo humano para identificar distintas características en las entradas que en definitiva hacen que pueda identificar objetos y “ver”. La CNN contiene varias capas ocultas especializadas y con una jerarquía: esto quiere decir que las primeras capas pueden detectar líneas, curvas y se van especializando hasta llegar a capas más profundas que reconocen formas complejas como un rostro o la silueta de un animal[21].

5.2.5. Arquitectura de una red Neuronal

Las CNNs están compuestas de diferentes filtros/núcleos, los cuales constituyen un conjunto de parámetros entrenables y que pueden convolucionar espacialmente una imagen dada para detectar características como bordes y formas. Este alto número de filtros esencialmente aprende a capturar características espaciales de la imagen en función de los pesos aprendidos a través de la propagación hacia atrás. Las arquitecturas CNNs se pueden encontrar con diversas variantes, sin embargo, en general se componen de capas convolucionales y de submuestreo que se encuentran agrupadas en módulos o bloques convolucionales[1].

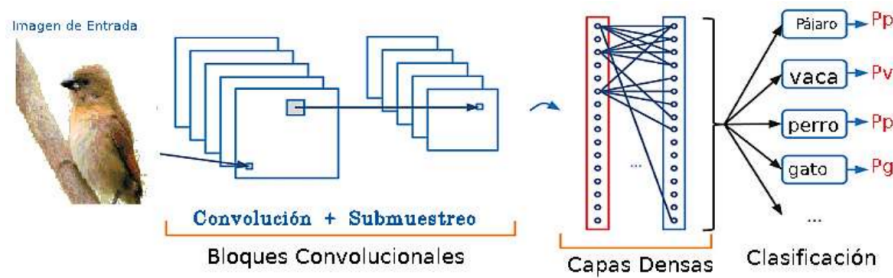


Figura 5.1: Arquitectura de Red Neuronal[1]

1. **Capa convolucional (Convolutional layer)** Es la capa principal de las redes de neuronas convolucionales, siendo indispensable el uso de una o de más capas de este tipo en dichas redes. Los parámetros en una capa convolucional en la práctica se refiere a un conjunto de filtros entrenable. Cada filtro ocupa un espacio pequeño a lo largo de las dimensiones de anchura y altura, pero se extiende por toda la profundidad del volumen de entrada al que se aplica[21]. Se realizan operaciones de productos y sumas entre la capa de partida y los n filtros (o kernel) que genera un mapa de características. La característica extraída corresponden a cada posible ubicación del filtro en la imagen original. La ventaja es que el mismo filtro (= neurona) sirve para extraer la misma característica en cualquier parte de la entrada, con esto que consigue reducir el número de conexiones y el número de parámetros a entrenar en comparación con una red multicapa de conexión total[2].

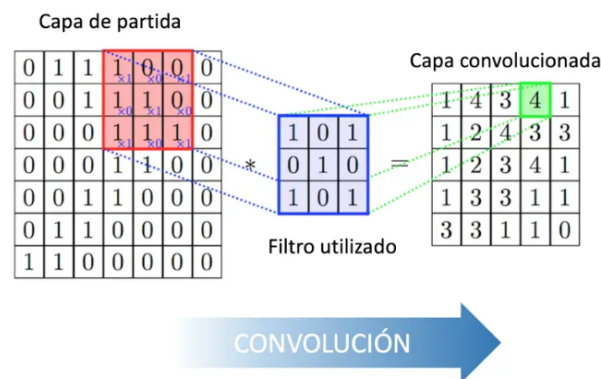


Figura 5.2: Arquitectura de convolución[2]

2. **Capa de agrupación (Pooling layer)** La capa de agrupación toma los mapas de características producidos en la capa de convolución y los agrupa en una imagen. En esta capa, se produce la reducción de dimensionalidad,

reduciendo de esta forma, la complejidad que posee el modelo, ayudando a evitar el sobreajuste del mismo. Es decir, lo que hacen las capas de agrupación es simplificar la información en la salida de la capa convolucional. El pooling es una operación que permite reducir la cantidad de parámetros de la red, por lo general, la operación describe la agrupación de manera operacional[2].

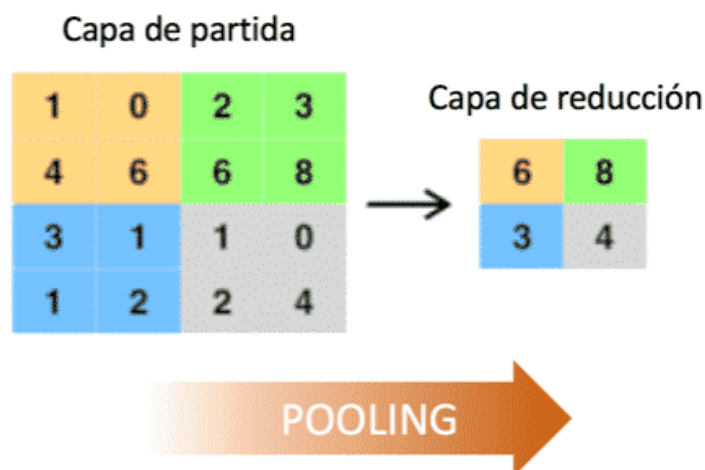


Figura 5.3: Reducción – pooling[2]

5.2.6. Visión por Computador

La visión por computador, también denominada visión artificial, es considerada una rama de la Inteligencia Artificial clásica. Esta incluye la serie de fases necesarias para dotar al ordenador de la capacidad de percibir y comprender una imagen de forma a tratar de imitar el proceso que realizan los seres humanos. Si bien la arquitectura y las etapas de un sistema de visión son dependientes de su aplicación, existen algunas etapas que se encuentran en la mayoría de las aplicaciones. Los sistemas de visión artificial poseen diferentes tipos de aplicaciones: de medición, de detección de fallas, de corrección y de reconocimiento; las cuales pueden ser utilizadas en áreas como la industria, la medicina y la robótica[3].

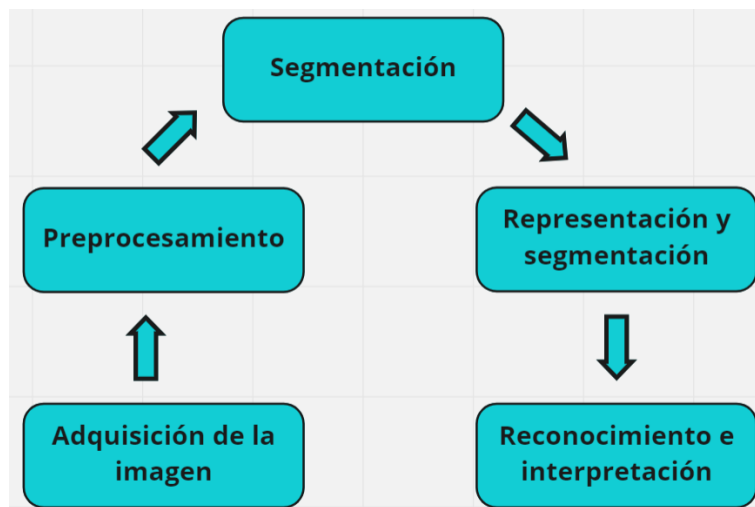


Figura 5.4: Etapas de un Sistema de Visión Artificial[3]

5.2.7. Reconocimiento de objetos

El reconocimiento de objetos es una técnica de visión artificial para identificar objetos en imágenes o vídeos. El reconocimiento de objetos constituye una salida clave del algoritmo de deep learning y machine learning. Cuando las personas observan una fotografía o un vídeo, se detecta con rapidez personas, objetos, lugares y detalles visuales. El objetivo es enseñar a un ordenador a hacer lo que resulta natural para los humanos: adquirir cierto nivel de comprensión del contenido de una imagen. La detección de objetos y el reconocimiento de objetos son técnicas similares para identificar objetos, pero varían en cuanto a su ejecución. La detección de objetos es el proceso de localizar objetos presentes en imágenes. En el caso de deep learning, la detección de objetos forma parte del reconocimiento de objetos, que no solo identifica el objeto, sino que lo localiza en una imagen. Esto permite identificar y localizar varios objetos en la misma imagen. La detección de objetos y el reconocimiento de objetos son técnicas similares para identificar objetos, pero varían en cuanto a su ejecución. La detección de objetos es el proceso de localizar objetos presentes en imágenes. En el caso de deep learning, la detección de objetos forma parte del reconocimiento de objetos, que no solo identifica el objeto, sino que lo localiza en una imagen. Esto permite identificar y localizar varios objetos en la misma imagen[4].

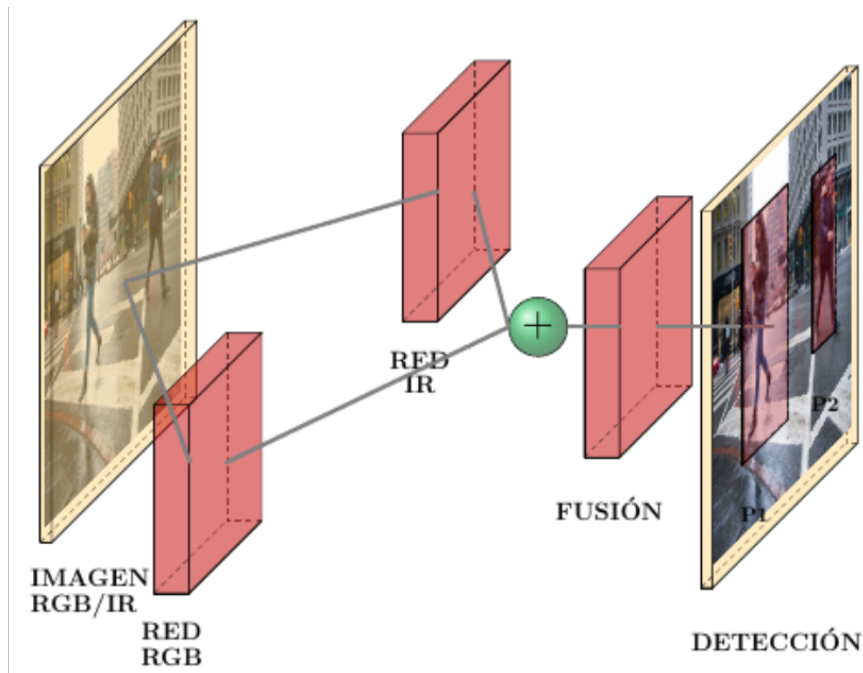


Figura 5.5: Detección de imagen[4]

5.2.8. Matriz de confusión

En el campo de la inteligencia artificial y el aprendizaje automático, una matriz de confusión es una herramienta que permite visualizar el desempeño de un algoritmo de aprendizaje supervisado. Cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real, en términos permite ver qué tipos de aciertos y errores está teniendo nuestro modelo a la hora de pasar por el proceso de aprendizaje con los datos[4].

5.2.8.1. La matriz de confusión como herramienta del aprendizaje automático

Imagine que tiene una prueba médica que verifica la presencia o ausencia de una enfermedad; en este caso si utilizara un algoritmo de aprendizaje automático basado en clasificación. Hay dos posibles verdades: lo que se está probando es verdadero o no. La persona está enferma o no lo está; la imagen es un perro, o no lo es. Debido a esto, también hay dos resultados de prueba posibles: un resultado de prueba positivo (la prueba predice que la persona está enferma o no, o bien en el otro ejemplo la imagen es un perro, o no)[4].



Figura 5.6: Matriz de confusión binaria[4]

Estas 4 opciones se conocen como la matriz de confusión. Existe los 4 resultados posibles:

- **Verdadero positivo:** El valor real es positivo y la prueba predijo también que era positivo. O bien una persona está enferma y la prueba así lo demuestra[4].
- **Verdadero negativo:** El valor real es negativo y la prueba predijo también que el resultado era negativo. O bien la persona no está enferma y la prueba así lo demuestra[4].
- **Falso negativo:** El valor real es positivo, y la prueba predijo que el resultado es negativo. La persona está enferma, pero la prueba dice de manera incorrecta que no lo está. Esto es lo que en estadística se conoce como error tipo II[4].
- **Falso positivo:** El valor real es negativo, y la prueba predijo que el resultado es positivo. La persona no está enferma, pero la prueba dice de manera incorrecta que sí lo está. Esto es lo que en estadística se conoce como error tipo I[4].

5.2.9. Python

Python es un lenguaje de programación de alto nivel que destaca por la legibilidad de su código y por la multitud de posibilidades que ofrece. Se le conoce como un

lenguaje de multiparadigma, ya que llega a soportar orientación a objetos, programación imperativa y, a menor, escala, programación funcional. Además, Python puede usarse para programación web, desarrollo de interfaces gráficas, librerías matemáticas, desarrollo de software y muchas más opciones. Actualmente, es el lenguaje de programación con mayor uso en el ámbito de la IA con librerías para computación científica, computación avanzada o aprendizaje automático[22].

5.2.9.1. Ventajas de Python con Inteligencia Artificial

Python ofrece a los desarrolladores la creación de potentes sistemas de backend para proyectos de Python AI. Hay muchos beneficios con este lenguaje de programación[4].

1. **Desarrollo rápido** La gran variedad de bibliotecas es una de las principales razones por las que Python es el lenguaje de programación más popular para la IA. Se puede entender una biblioteca como un módulo o un grupo de módulos publicados por diferentes fuentes como PyPi que incluyen un fragmento de código prescrito que permite a los usuarios alcanzar alguna funcionalidad o realizar diferentes acciones. Las bibliotecas de Python proporcionan elementos de nivel básico para no codificarlos desde el principio. De esta manera, reducen su tiempo de aprendizaje de las complejidades del stack y así pueden comenzar con el desarrollo de Inteligencia Artificial (IA) y pasar a la creación de Algoritmo y programas de IA[4].
 2. **Lenguaje flexible** Tiene la máxima flexibilidad para las aplicaciones de IA. Para Machine Learning permite elegir OOPS o programación basada en secuencias de comandos. No es necesario volver a compilar el código fuente, y se puede implementar cambios y ver de forma inmediata los resultados. Existen 4 estilos diferentes de desarrollo en Python para elegir: el estilo imperativo, consta de comandos que describen cómo un ordenador debe ejecutar esos comandos; el estilo funcional, declara qué operaciones deben realizarse en forma de ecuaciones matemáticas; el estilo orientado a objetos, se basa en objetos similares que forman clases, se puede usar en un grado finito y, el estilo procedimental, es el más común para los principiantes, ya que realiza tareas en un formato paso a paso[4].
 3. **Legibilidad** Python es un lenguaje muy fácil de leer, cada desarrollador que emplee esta herramienta puede entender el código de sus compañeros y cambiarlo, copiarlo o compartirlo. No existen confusiones, errores o conflictos, lo que provoca un intercambio eficiente de algoritmo, ideas y herramientas entre los profesionales de Inteligencia Artificial y Machine Learning. Existen herramientas como IPython, que es un shell interactivo que facilita funciones adicionales como pruebas, depuración, etc. optimizando el proceso de trabajo[4].
-

4. **Visualización** Python ofrece una variedad de bibliotecas, y, entre ellas, existen herramientas de visualización. No obstante, para los desarrolladores de Inteligencia Artificial y Machine Learning es de vital importancia representar datos de forma legible para los humanos, para determinar patrones y dar sentido a todas las variables y factores. También existe la Biblioteca como Matplotlib permiten crear gráficos, histogramas y diagramas para una mejor comprensión, presentación y visualización de los datos[4].

5.2.10. Keras

Keras es una API diseñada para seres humanos, no para máquinas, sigue las mejores prácticas para reducir la carga cognitiva: ofrece API consistentes y simples, minimiza la cantidad de acciones del usuario requeridas para casos de uso comunes y proporciona mensajes de error claros y accionables. También tiene una extensa documentación y guías para desarrolladores. Keras es una API de redes neuronales a alto nivel, escrita en Python y que puede emplearse haciendo uso de TensorFlow, CNTK o Theano. Fue desarrollada con el enfoque de permitir una experimentación rápida, es decir, pasar de la idea al resultado con el menor retraso posible. Entre sus características destacan[23]:

- Permite una creación de prototipos fácil y rápida (a través de la facilidad de uso, la modularidad y la extensibilidad). Redes convolucionales y redes recurrentes, así como la combinación de ambas.
 - Funciona a la perfección tanto en CPU's como en GPU's. De dicha API se han extraído métodos que posteriormente se mencionan y que en la sección de los Anexos se pueden ver cómo se ha empleado en la elaboración de código.
 - **Keras.layers:** donde se describen todos los métodos que poseen las capas keras en común[23].
 - Keras.layers.convolutional: aquí se encuentran los métodos utilizados para llevar a cabo las convoluciones en las redes neuronales del proyecto. En nuestra aplicación se han utilizado las convoluciones en dos dimensiones[23].
 - Keras.layers.core: de núcleo se obtienen los métodos relacionados con las funciones de activación, el dropout, etc[23].
 - Keras.layers.normalization: de este paquete se obtienen métodos que permiten la normalización de los batches (Batch Normalization) y otros métodos que, aunque no se utilizan en la elaboración del proyecto, son interesante mencionar como: Bidirectional o TimeDistributed[23].
 - Keras.models: en Keras hay dos tipos principales de modelos: Sequential (secuencial) y Model class (clase modelo)[23].
-

- Keras.regularizers: los regularizadores permiten aplicar penalizaciones en los parámetros de capa o en la actividad de capa durante la optimización. Estas penalizaciones se incorporan en la función de pérdida que la red optimiza[23].

5.2.11. TensorFlow

TensorFlow es un software de computación numérica creado por Google, orientado a problemas de Deep Learning. Posee interesantes integraciones con otras bibliotecas del ecosistema como Keras, de la que se hablará más adelante. En el proyecto se explotará la utilidad que presenta para construir y entrenar redes neuronales. TensorFlow es una librería desarrollada a partir de la combinación de C++ y CUDA. El hecho de emplear Python supone un ahorro en cuanto a la declaración del tipo de variables que se obtienen como resultado de las ejecuciones, simplicidad a la hora de utilizar dichas variables, el manejo de vectores y matrices, etc. La principal estructura de datos que se maneja en esta librería son los tensors. Con un tensor se referirá a un conjunto de valores primitivos, por ejemplo números enteros o flotantes, organizados por un array de 1 o N dimensiones, donde el rango del tensor sería el número de dimensiones[24]. TensorFlow, creado originalmente por investigadores de Google, es el más popular entre la pléthora de bibliotecas de aprendizaje profundo. En el campo del aprendizaje profundo, las redes neuronales han logrado un gran éxito y han ganado una gran popularidad en varias áreas. Esta familia de modelos también tiene un tremendo potencial para promover el análisis de datos y el modelado de diversos problemas en las ciencias de la educación y del comportamiento, dada su flexibilidad y escalabilidad. La implementación de estos modelos y algoritmo de optimización requiere mucho tiempo y es propensa a errores. Afortunadamente, TensorFlow facilita y acelera en gran medida la investigación y la aplicación de modelos de redes neuronales. Se revisa varios conceptos básicos de TensorFlow, como las funciones de construcción de gráficos, las herramientas de ejecución de gráficos y la herramienta de visualización de TensorFlow, TensorBoard. Se aplica para construir y entrenar, un modelo de red neuronal convolucional para clasificar dígitos escritos a mano. Esta revisión concluye con una comparación de las interfaces de programación de aplicaciones de bajo y alto nivel y una discusión sobre el soporte de la unidad de procesamiento gráfico, el entrenamiento distribuido y el modelado probabilístico con la biblioteca TensorFlow Probability [25].

5.3. Trabajos relacionados

Con base a la bibliografía revisada, en bases de datos científicas existen diversas soluciones informáticas relacionadas con los modelos de detección de enfermedades, enfocadas a redes neuronales convolucionales, haciendo uso de imágenes de las hojas.

Título	Resumen
Visión por computadora para el manejo de plagas y enfermedades en cultivos de papa.	La presente investigación hace uso de técnicas de aprendizaje profundo, haciendo uso de las redes neuronales convolucionales al momento de resolver la tarea de clasificar imágenes. Utilizaron imágenes de hojas de papa obtenidas del conjunto de datos PlantVillage e imágenes de tubérculos obtenidas del conjunto de datos Fruit360 con adición de imágenes de recopilación propia, como entrada para modelos entrenados a partir de las arquitecturas VGG16 y DenseNet201. Como resultado se obtuvo un modelo capaz de diferenciar entre las clases sana, tizón temprano y tizón tardío con una precisión del 98.44% para el caso de las hojas, y un modelo capaz de diferenciar entre las clases sana, tizón tardío y sarna común con una precisión del 96.88% para el caso de los tubérculos, además, se generaron visualizaciones de los mapas de características, de las principales capas convolucionales de la red VGG16, permitiendo una interpretación y análisis visual [26].
Técnicas de aprendizaje automático para la agrupación, predicción y clasificación de enfermedades de las plantas de tomate.	Este estudio utiliza modelos de aprendizaje automático para agrupar, predecir y clasificar las enfermedades de las plantas de tomate en Palestina. Los modelos de aprendizaje automático utilizaron técnicas de incrustación de imágenes y agrupación jerárquica en la agrupación, y red neuronal, Random Forest, naïve Bayes, SVM, Decision Tree y regresión logística para predicción y clasificación. El modelo es validado en referencia a una base de datos de enfermedades de plantas de tomate. El modelo agrupa 7 enfermedades con una tasa de precisión del 70%, los modelos de red neuronal y de regresión logística tienen un rendimiento 70,3% y 68,9%, respectivamente. El modelo de agrupamiento proporcionó un agrupamiento de 7 enfermedades con una tasa de precisión del 70%, mientras que los modelos de red neuronal y de regresión logística informaron precisiones de rendimiento del 70,3% y el 68,9%, respectivamente [27].

<p>Modelo de aprendizaje profundo para la predicción temprana de enfermedades de las plantas.</p>	<p>Este trabajo de investigación se centra en uno de los principales retos en el suelo agrícola como es la predicción de enfermedades. La enfermedad en las plantas de cultivo afecta la producción agrícola, por lo que se propone un modelo para automatizar un método para la predicción de enfermedades en las plantas e intimar a los agricultores a tomar las medidas adecuadas de antemano. En este trabajo, se propone un modelo de aprendizaje profundo que clasifica con precisión cualquier imagen de hoja si tiene una enfermedad o no, además de proporcionar un tipo de enfermedad. Las imágenes de las plantas de tomate se extrajeron del conjunto de datos de Plant Village y se entrenaron usando modelos previamente entrenados como VGG16 y Dense Net usando el aprendizaje de transferencia y se comparó su precisión. Por lo tanto, el sistema propuesto en combinación con su interpretabilidad y precisión medidas puede ayudar de manera efectiva a los agricultores en el diagnóstico temprano de la hoja enferma[28].</p>
<p>DeepTrac: aplicación de la inteligencia artificial en la detección de enfermedades de las plantas.</p>	<p>En esta investigación trabaja con un modelo automatizado de detección de enfermedades de plantas basado en IA-aprendizaje profundo utilizando FPN con arquitectura Faster R-CNN. El método se experimenta con la detección de manchas bacterianas en imágenes de hojas de plantas de pimiento obtenidas del conjunto de datos de PlantVillage. El modelo propuesto logró una precisión promedio del 100% y un recuerdo promedio del 99,7% para una relación IoU(proporción de intersección sobre unión) de 0,5; la precisión media fue del 99,5% y la recuperación media fue del 99,1% para un IoU de 0,5-0,95[29].</p>
<p>dCrop: un marco basado en aprendizaje profundo para la predicción precisa de enfermedades de cultivos en agricultura inteligente.</p>	<p>La identificación rápida de las enfermedades que afectan los cultivos sigue siendo difícil en diferentes partes del mundo debido a la limitada disponibilidad de infraestructura. La investigación utiliza tecnología de visión artificial y métodos de aprendizaje profundo para predecir las enfermedades de los cultivos. Se entrena una red neuronal convolucional profunda DNN en un conjunto de datos público de 54.306 imágenes que consisten en hojas de plantas sanas y enfermas. El modelo entrenado tiene una precisión del 99,24% y puede identificar 14 especies de cultivos y 26 enfermedades[30].</p>

<p>A Polyhouse: Monitoreo de plantas y detección de enfermedades usando CNN.</p>	<p>El conjunto de datos utilizado para este trabajo contiene imágenes de varias plantas que consisten en hojas sanas y enfermas. La red neuronal de convolución (CNN), es utilizada para entrenar el modelo para detectar las enfermedades. Las plantas consideradas incluyen plantas de Maíz, Fresa, Uva, Tomate y Papa. El modelo predice la salud de la mayoría de las plantas con una precisión óptima de predicción del 85% y se observó una pérdida insignificante de 0,25 en el curso del entrenamiento de los datos [31].</p>
<p>Clasificación y predicción de enfermedades de las plantas de arroz mediante la red neuronal convolucional.</p>	<p>Este trabajo propone una solución innovadora con procesamiento de imágenes y red neuronal de convolución (CNN) para clasificar las plantas de arroz como pertenecientes a clases de tipo de enfermedad en función de los datos obtenidos de los repositorios de bases de datos de imágenes. CNN es una elección natural, ya que es un algoritmo de aprendizaje profundo asociado con una convergencia más rápida, precisión en las clasificaciones con conjuntos mínimo de entrenamiento[32].</p>
<p>Visión por computador para reconocimiento de malezas en Cultivos de tomate riñón de invernadero, mediante redes Neuronales.</p>	<p>El trabajo de titulación. Para su desarrollo, utiliza un sistema de reconocimiento de visión por computador mediante redes neuronales; el mismo que se inicia con la adquisición de datos, se procede a etiquetarlos mediante el Software LabelImg. Con la utilización de un dispositivo embebido interactuando con una pantalla para visualizar el resultado, se dispone de un sistema en Python con el que se logra realizar las pruebas de funcionamiento; con las que se verifica el correcto funcionamiento de este. Las pruebas se las realiza con imágenes, videos guardados o en tiempo real[33].</p>

Tabla 5.1: Trabajos relacionados

Mediante los siguientes trabajos relacionados se logró determinar parte de los objetivos, alcance y marco teórico, donde se evidencia que para la detección de objetos hacen uso de las redes neuronales convolucionales, con lo cual aporta al presente trabajo como fuente de investigación y conocimiento de las tecnologías a emplear.

6. Metodología

Objetivo	Tareas/Actividades	Métodos	Materiales	Producto	Lugar	Responsable
Identificar métodos, técnicas basadas en inteligencia artificial y recopilar data sets con imágenes de hojas sanas y enfermas del tomate de riñón.	Construcción de datos.	Analítica, Experimental, Investigación - Acción	Computadora, cámara, Fotografías	Conjunto de datos(imágenes) clasificadas y agrupadas.	El cantón Saraguro, Carrera de Ingeniería en Sistemas/Computación, Aulas de la UNL	Sisa Parra
	Revisar información relacionada al tema de investigación para identificar métodos y técnicas utilizados en el desarrollo de modelos basados en visión por computador.					
	Buscar en data sets y bases de datos imágenes accesibles de la hoja de tomate de riñón.					
	Adquirir los datos mediante, imágenes de hoja de tomate de riñón, que permita entrenar, evaluar el modelo y distinguir la enfermedad.					
	Preparar los datos mediante el etiquetado de imágenes, que cumplen con los criterios de aceptación y basándose en el formato permitido por los modelos.					
	Dividir en set de datos en Entrenamiento, Validación y Prueba.					
Desarrollar un modelo de visión por computador para la detección automática de la enfermedad Tizón Tardío (<i>Phytophthora infestans</i>) en las hojas del tomate de riñón.	Desarrollo del modelo.	Investigativo, Estudio de Caso Analítico Experimental	Computadora, Navegador, Python, Data Set	Modelo funcional capaz de determinar la enfermedad en las hojas de tomate.	El cantón Saraguro, Carrera de Ingeniería en Sistemas/Computación, Aulas de la UNL	Sisa Parra
	Utilizar un modelo de visión por computador, para construir un modelo capaz de diagnosticar la enfermedad a partir de las hojas de tomate de riñón.					
	Construir el modelo para determinar la enfermedad en la hoja de tomate de riñón.					
	Entrenar el modelo utilizando el conjunto de datos obtenidos para el entrenamiento.					
Validar el modelo de visión por computador en un escenario de prueba aplicada a los invernaderos del cantón Saraguro.	Evaluación del modelo.	Analítico, Experimental cuantitativo	Computadora, Python	Informe de las evaluaciones del modelo.	El cantón Saraguro, Carrera de Ingeniería en Sistemas/Computación, Aulas de la UNL	Sisa Parra
	Evaluar los resultados obtenidos por el modelo en cuanto al diagnóstico de enfermedad en la hoja de tomate de riñón.					
	Validar y contrastar los resultados obtenidos en un escenario de prueba con la opinión de un experto.					

Figura 6.1: Metodología del PTT

7. Cronograma

El trabajo de titulación denominado “Modelo predictivo basado en visión por computador para identificar enfermedades en las hojas del tomate de riñón (*Solanum lycopersicum*) del Cantón Saraguro”, requiere de una buena planificación de las actividades, partiendo de esto, la autora del proyecto plantea seguir el cronograma descrito, con el fin de llevar a cabo las tareas/actividades en tiempos establecidos y llevar un control permanente. Con el fin de evitar retrasos en la entrega del producto final.

CRONOGRAMA DE ACTIVIDADES																					
ACTIVIDADES	DURACIÓN	MES 1				MES 2				MES 3				MES 4				MES 5			
		Semana				Semana				Semana				Semana				Semana			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Etap 1: Identificar métodos, técnicas basadas en inteligencia artificial y recopilar data sets con imágenes de hojas sanas y enfermas del tomate de riñón.																					
Revisar información relacionada al tema de investigación para identificar métodos y técnicas utilizados en el desarrollo de modelos basados en visión por computador.	5 días																				
Buscar en data sets y bases de datos imágenes accesibles de la hoja de tomate de riñón.	5 días																				
Adquirir los datos mediante, imágenes de hoja de tomate de riñón, que permita entrenar, evaluar el modelo y distinguir la enfermedad.	5 días																				
Preparar los datos mediante el etiquetado de imágenes, que cumplen con los criterios de aceptación y basándose en el formato permitido por los modelos.	5 días																				
Dividir en set de datos en Entrenamiento, Validación y Prueba	5 días																				
Fase 2: Desarrollar un modelo de visión por computador para la detección automática de la enfermedad Tizón Tardío (Phytophthora infestans) en las hojas del tomate de riñón.																					
Utilizar un modelo de visión por computador, para construir un modelo capaz de diagnosticar la enfermedad a partir de las hojas de tomate de riñón.	10 días																				
Construir el modelo para determinar la enfermedad en la hoja de tomate de riñón.	30 días																				
Entrenar el modelo utilizando el conjunto de datos obtenidos para el entrenamiento.	15 días																				
Fase 3: Validar el modelo de visión por computador en un escenario de prueba aplicada a los invernaderos del cantón Saraguro.																					
Evaluar los resultados obtenidos por el modelo en cuanto al diagnóstico de enfermedad en la hoja de tomate de riñón.	10 días																				
Validar y contrastar los resultados obtenidos en un escenario de prueba con la opinión de un experto.	10 días																				

Figura 7.1: Cronograma del PTT

8. Presupuesto

Para el desarrollo del presente trabajo de titulación (TT), se requiere de algunos recursos, entre estos se encuentra el económico, por lo que se propone el siguiente presupuesto que está dado por algunas categorías, como son: Talento Humano, Recursos Técnicos y Tecnológicos, Recursos Materiales y Servicios.

8.1. Recursos Humano

Responsable	Horas	Valor (H)	Subtotal
1 Estudiante	400	\$ 14	\$ 5,600
1 Tutor	200	\$ 20	\$ 4,000
Total:			\$ 9,600

Tabla 8.1: Recursos Humanos

8.2. Recursos Tecnológico

Recurso	Cantidad	Valor Unitario	Subtotal
Mendeley	1	\$ 0	\$ 0
Computadora	1	\$ 1,400	\$ 1,400
Google Colab	1	\$ 0	\$ 0
Total:			\$ 1,400

Tabla 8.2: Recursos Tecnológico

8.3. Recursos Materiales

Material	Cantidad	Valor Unitario	Subtotal
Resma de Papel	1	\$ 5	\$ 5
Esferos	5	\$ 0,50	\$ 2,50
Utensilios de oficina	5	\$ 2	\$ 10
Empastado	1	\$ 30	\$ 30
Total:			\$ 47.50

Tabla 8.3: Recursos Materiales

8.4. Servicios

Servicio	Meses	Valor/Meses	Subtotal
Internet Fijo	5	\$ 40	\$ 200
Internet Móvil	5	\$ 10	\$ 50
Transporte	5	\$ 20	\$ 100
Impresión	5	\$ 30	\$ 150
Total:			\$ 500

Tabla 8.4: Servicios

8.5. Presupuesto total para la elaboración del proyecto

Recursos/Servicios	Subtotal
<i>Recursos Humanos</i>	<i>\$9,600</i>
<i>Recursos Técnicos/Tecnológicos</i>	<i>\$1,400</i>
<i>Recursos Materiales</i>	<i>\$47.50,</i>
<i>Servicios</i>	<i>\$500</i>
<i>Subtotal</i>	<i>\$11,547.50</i>
<i>Imprevisto(10% subtotal)</i>	<i>\$1,154.75</i>
Presupuesto Total del Proyecto	\$12,702.25

Tabla 8.5: Presupuesto total para la elaboración del proyecto

Para el desarrollo del presente "Modelo predictivo basado en visión por computador para identificar enfermedades en las hojas del tomate de riñón (*Solanum lycopersicum*) del Cantón Saraguro", se estima el costo de \$12,702,25. En el presupuesto se estima un valor de 10% del subtotal para gastos imprevistos, además se aclara que los gastos que demanda el director y el docente responsable del PTT será financiado por la autora del presente proyecto y el recurso humano por parte de la Universidad Nacional de Loja.

Bibliografía

- [1] M. Villanueva, “Diseño de una arquitectura de red neuronal convolucional para la clasificación de objetos,” *Ciencia Nicolaita*, no. 81, pp. 46–61, 2021.
- [2] D. Calvo, “Red neuronal convolucional cnn.” <https://www.diegocalvo.es/red-neuronal-convolucional/>, 2017.
- [3] A. Cantero and J. Martínez, “Visión por computadora: identificación, clasificación y seguimiento de objetos,” *FPUNE Scientific*, no. 10, 2016.
- [4] MathWorks, “Procesamiento de imágenes y visión artificial - ¿qué es el reconocimiento de objetos?.” <https://es.mathworks.com/solutions/image-video-processing/object-recognition.html>.
- [5] D. Zamora-Oduardo, P. Rodríguez-Fernández, A. Ferrer-Dubois, Y. Fung-Boix, E. Isaac-Aleman, and G. Asanza-Kindelán, “Producción de tomate (*solanum lycopersicum* l.) bajo riego con agua magnetizada en casa de cultivo protegido,” *Ciencia en su PC*, vol. 1, pp. 60–74, 2020.
- [6] S. Interempresas Media, “Frutas - hortalizas/ tomate, *lycopersicon esculentum* / *solanaceae*.” <https://n9.cl/e9vmb>, 2022.
- [7] V. Obregón, “Guía para la identificación de las enfermedades de tomate en invernadero,” 2014.
- [8] C. Villasanti and A. Pantoja, “El cultivo de tomate con buenas prácticas agrícolas en la agricultura urbana y periurbana,” *Recuperado de http://www.fao.org/3/a-i3359s.pdf*, 2013.
- [9] S. Caceres, “Guía práctica para la identificación y el manejo de las plagas del tomate,” tech. rep., Estación Experimental Agropecuaria Bella Vista, INTA, 2020.
- [10] M. de Agricultura y Ganadería, “Boletín situacional tomate riñon,” 2017.
- [11] P. César, “Respuesta sanitaria y productiva del tomate riñon establecido bajo diferentes sistemas intercalados de producción,” B.S. thesis, Calceta: ESPAM MFL, 2020.
- [12] C. de Nacionalidades Indígenas del Ecuador, “Saraguro - confederación de nacionalidades indígenas del ecuador.” <https://n9.cl/mufcv>, 2014.

- [13] C. Salazar, “Análisis de las dimensiones de capital social en el cantón zapotillo, provincia de loja,” B.S. thesis, 2017.
 - [14] E. Rodríguez, “Efecto de cinco recubrimientos de polipropileno no tejido en parámetros productivos en tomate riñón (*solanum lycopersicum*) en puéllaro-ecuador,” B.S. thesis, Quito, 2020.
 - [15] P. Coral, “Identificación de los daños causados por botrytris en el cultivo de tomate de riñón (*lycopersicum esculentum* mill), bajo invernadero, en la comunidad san josé, cantón pimampiro, provincia de imbabura,” B.S. thesis, El Angel: UTB, 2019, 2019.
 - [16] M. Quizhpilema, “Biocontrol de la marchitez vascular en tomate riñón (*lycopersicon esculentum*) en un cultivo bajo invernadero mediante hongos antagonistas del género *trichoderma*,” Master’s thesis.
 - [17] M. Boden, *Inteligencia artificial*. Turner, 2017.
 - [18] D. Rolnick, P. Donti, L. Kaack, K. Kochanski, A. Lacoste, K. Sankaran, A. S. Ross, N. Milojevic-Dupont, N. Jaques, A. Waldman-Brown, *et al.*, “Tackling climate change with machine learning,” *ACM Computing Surveys (CSUR)*, vol. 55, no. 2, pp. 1–96, 2022.
 - [19] J. Wei, X. Chu, K. Sun, Xiang and, H. Deng, J. Chen, Z. Wei, and M. Lei, “Machine learning in materials science,” *InfoMat*, vol. 1, no. 3, pp. 338–358, 2019.
 - [20] M. Gegúndez Arias and I. Pérez Borrero, “Deep learning: fundamentos, teoría y aplicación,” *Deep learning*, pp. 1–261, 2021.
 - [21] C. Bonilla Carrión, “Redes convolucionales (trabajo fin de grado inédito). universidad de sevilla, sevilla,” 2020.
 - [22] F. Bellido Delgado, “Narrativa digital con inteligencia artificial en python, universidad de alicante. departamento de lenguajes y sistemas informáticos,” 2022.
 - [23] A. Gulli and S. Pal, *Deep learning with Keras-Implementing deep learning models and neural networks with the power of Python*. Packt Publishing Ltd, 2017.
 - [24] A. Grigorev, R. Shanmugamani, A. Boschetti, L. Massaron, and A. Thakur, *TensorFlow Deep Learning Projects: 10 real-world projects on computer vision, machine translation, chatbots, and reinforcement learning*. Packt Publishing Ltd, 2018.
 - [25] B. Pang, E. Nijkamp, and Y. N. Wu, “Deep learning with tensorflow: A review,” *Journal of Educational and Behavioral Statistics*, vol. 45, no. 2, pp. 227–248, 2020.
-

-
- [26] F. Fabián, “Visión por computadora para el manejo de plagas y enfermedades en cultivos de papa,” 2021.
- [27] R. Qasrawi, M. Amro, R. Zaghal, M. Sawafteh, and S. V. Polo, “Machine learning techniques for tomato plant diseases clustering, prediction and classification,” in *2021 International Conference on Promising Electronic Technologies (ICPET)*, pp. 40–45, IEEE, 2021.
- [28] P. Rubini and P. Kavitha, “Deep learning model for early prediction of plant disease,” in *2021 Third International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)*, pp. 1104–1107, IEEE, 2021.
- [29] B. Biswal and S. Chestnut, “Deeptrac: Applying artificial intelligence in plant disease detection,” in *SoutheastCon 2022*, pp. 233–236, IEEE, 2022.
- [30] V. Pallagani, V. Khandelwal, B. Chandra, V. Udutalapally, D. Das, and S. P. Mohanty, “Dcrop: A deep-learning based framework for accurate prediction of diseases of crops in smart agriculture,” in *2019 IEEE International Symposium on Smart Electronic Systems (iSES)(Formerly iNiS)*, pp. 29–33, IEEE, 2019.
- [31] N. Radha and R. Swathika, “A polyhouse: Plant monitoring and diseases detection using cnn,” in *2021 International Conference on Artificial Intelligence and Smart Systems (ICAIS)*, pp. 966–971, IEEE, 2021.
- [32] G. Sagarika, S. K. Prasad, and S. M. Kumar, “Paddy plant disease classification and prediction using convolutional neural network,” in *2020 International Conference on Recent Trends on Electronics, Information, Communication & Technology (RTEICT)*, pp. 208–214, IEEE, 2020.
- [33] K. Suárez, “Visión por computador para reconocimiento de malezas en cultivos de tomate riñón de invernadero, mediante redes neuronales,” B.S. thesis, 2021.
-

Lista de Acrónimos y Abreviaturas

CIS	Carrera de Ingeniería en Sistemas.
CNN	Redes Neuronales Convolucionales.
DL	Deep Learning.
FEIRNR	Facultad de la Energía, las Industrias y los Recursos No Renovables.
GADMIS	Gobierno Autónomo Descentralizado del Cantón Saraguro.
IA	Inteligencia Artificial.
IEEE	Institute of Electrical and Electronics Engineers.
ML	Machine Learning.
TFG	Trabajo Final de Grado.
UBU	Unidad de Bienestar Estudiantil.
UNL	Universidad Nacional de Loja.

A. Anexo I. Modelo de la entrevista

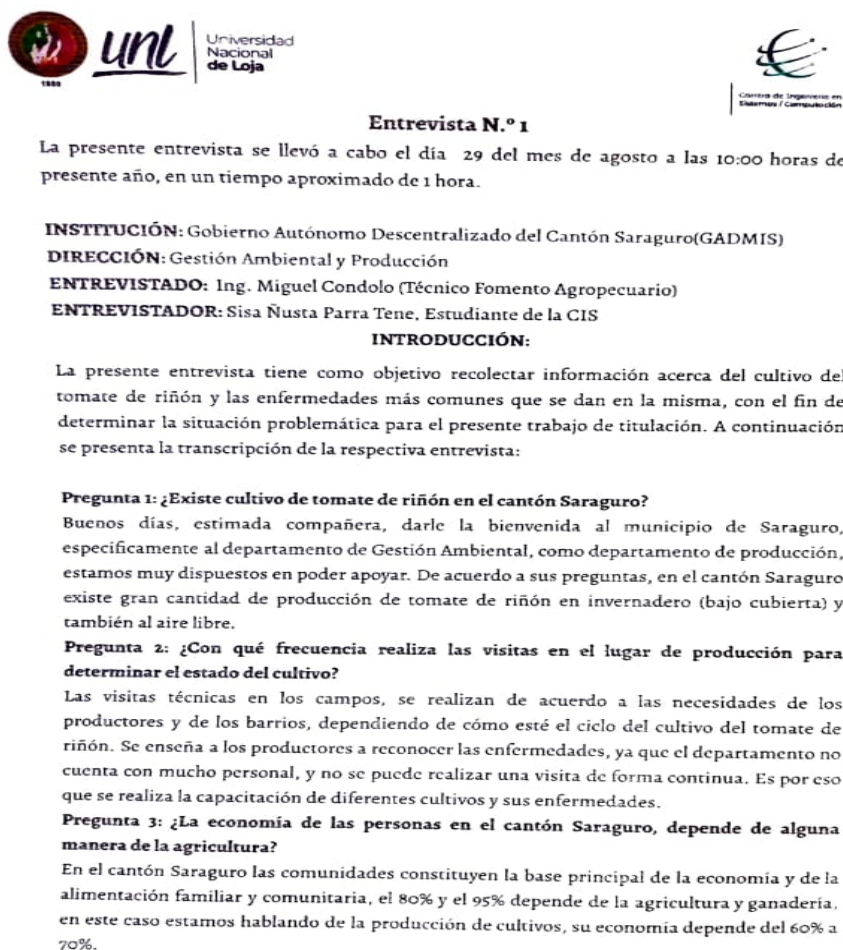


Figura A.1: Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.1



Pregunta 4: ¿Cuál es la variedad más común de tomate de riñón que se cultiva en el cantón Saraguro?

Aunque existen diferentes variedades de tomate de riñón, en nuestro cantón no todas pueden ser cultivadas, ya que debido al tipo de suelo y clima existente, solamente se han adaptado variedades como, titán, dominique y pietro, siendo este último el más cultivado por los agricultores saragurenses, debido a la cantidad de racimos que produce y por tener un tiempo de vida útil más largo.

Pregunta 5: ¿Cuáles son las enfermedades que se presentan en el cultivo de tomate de riñón?

El cultivo del tomate es muy susceptible al ataque de plagas y enfermedades, debido al monocultivo del tomate de riñón que ha existido en los últimos tiempos se han proliferado un sin número de enfermedades y plagas, entre las más comunes que se encuentran al inicio y en etapa de cosecha del cultivo es la Cenicilla (*Oidium*), tizón tardío, *Fusarium* (Marchitamiento), mancha gris, botrytis, mosca blanca, entre otros.

Pregunta 6: ¿Cuál es la enfermedad más común que se presenta en el cultivo de tomate de riñón, de acuerdo a su experiencia, en el cantón Saraguro?

Durante mi experiencia, y con base a los seguimientos que se han mantenido en diferentes sectores de esta plantación, se puede determinar que las enfermedades que afectan a las plántulas del cultivo de tomate en nuestro cantón y debido al clima y tipo de suelo son, el oidio conocido como cenicilla, tizón tardío y la mancha gris, estas enfermedades son peligrosas, ya que pueden dañar gran porcentaje del cultivo.

Pregunta 6: ¿Las características en las hojas, y las enfermedades en la planta de tomate, varían de acuerdo al tipo?

En plantas levemente afectadas se observa que de acuerdo al ciclo de la enfermedad varían, al inicio se manifiestan como lesiones de acuerdo al tipo de enfermedad que tiene un cultivo, es decir que si al principio tiene una enfermedad un cultivo tiene un color, pero al pasar en ocho, tres o cinco días ya varía ese tipo de coloración y sobre todo la marchitez de las hojas.

Pregunta 8: ¿La enfermedad mencionada anteriormente se puede determinar desde sus etapas tempranas por medio de la hoja?

Si ya que los síntomas generalmente se observan en hojas, al inicio se manifiestan como lesiones, todas estas enfermedades, sus primeras, síntomas se encuentran en hojas, luego paulatinamente de acuerdo al proceso de esta enfermedad van al tallo, luego a los frutos.

Pregunta 9: ¿Los pequeños productores de tomate conocen el nombre exacto de cada enfermedad de la misma?

Paulatinamente, de acuerdo a la experiencia, por medio de las distintas capacitaciones han ido conociendo y diferenciando las distintas enfermedades, además de saberlas tratar y

Figura A.2: Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.2



Universidad
Nacional
de Loja



Centro de Ingeniería en
Sistemas / Computación

manejar, a pesar de ello existen aún muchos que se confunden, por lo cual vienen a los centros agroecológicos para pedir ayuda, de acuerdo a las capacitaciones los productores van reconociendo este tipo de enfermedades, sobre todo para el cuidado y manejo de este mismo.

Pregunta 10: ¿Cree que la detección temprana de una enfermedad en el cultivo ayuda a brindar tratamiento oportuno y mejorar la producción?

Si bien no existe una estimación de pérdida de rendimiento, es notorio el atraso que sufre la planta en su desarrollo y la mayor susceptibilidad a enfermedades. La detección temprana ayudaría el 100%, es muy importante tener conocimiento de un manejo adecuado para este tipo de cultivos, porque si nosotros no reconocemos el manejo adecuado de este tipo de enfermedades podemos perder el 100% de la producción, es por ello de que los productores, tiene toda la capacidad y con las capacitaciones que hemos hecho, tiene la predisposición de poder reconocer estas enfermedades y poder dar un tratamiento a tiempo, en uso de productos agroquímicos o también como májeos agroecológicos.

Pregunta 11: ¿El implementar un sistema de reconocimiento de enfermedades de tomate riñón ayuda en cuanto a tiempo y dinero a los agricultores?

Yo creé que es muy importante, el avance tecnológico no sabría sobre todo a reconocer este tipo de enfermedad, porque con la implementación de este tipo de sistemas en un emprendimiento de esta naturaleza, en este caso el cultivo de tomate de riñón sería muy factible para el productor, porque avanza a reconocer a temprana edad, los problemas que puede causar las enfermedades en este cultivo.

Alcaldía de
SARAGURO
Gobierno Autónomo Descentralizado
Municipal Intercultural de Saraguro
GESTIÓN AMBIENTAL Y PRODUCCIÓN
FOMENTO AGROPECUARIO

Ing. Miguel Condolo
TÉCNICO FOMENTO AGROPECUARIO
DEPARTAMENTO
DE PRODUCCIÓN Y GESTIÓN
AMBIENTAL
GADMIS

Sisa Parra
Entrevistadora
Estudiante de la CIS

Figura A.3: Entrevista al Técnico de fomento Agropecuario del GADMIS. Pag.3